AI基础

01-数学基础

01-1 Linear Algebra

01-2 Regression

> **Question**
>
> 在一组数据点中找到一个多项式函数，拟合这组数据 (Linear/Polynomial Regression)
> 数据为 $\mathbf{x} = (x_1, \ldots, x_N)^T, \mathbf{t} = (t_1, \ldots, t_N)^T$
> 求"最佳"参数$\mathbf{w} = (w_0, \ldots, w_M)^T$

令M次多项式函数$y(x, \mathbf{w}) = \sum_{j=0}^{M} w_j x^j$，误差函数$E(\mathbf{w}) = \frac{1}{2}\sum_{n=1}^{N}(y(x_n, \mathbf{w}) - t_n)^2$，"最佳拟合"即为使得$E(\mathbb{w})$最小的$\mathbb{w}$

> **是不是$\mathbb{w}$越大越好呢?**
>
> 多项式次数过高会导致**过拟合**
> 训练数据过少，参数过多可能会**过拟合**

- 过拟合解决方案:
  - 增加数据量
  - 权重正则化

01-3 Probability Theory

CS229-Mathmatical Fundamentals

[CS229-Probability Review]

概率的定义

- 概率三要素
  - 样本空间Ω
  - 事件空间$\mathcal{F} \subset 2^{\Omega}$
  - 概率测度$P : \mathcal{F} \to [0, 1]$
- 联合概率:
  - $X = x_i$ 和 $Y = y_j$同时发生的概率

    - Sum Rule
        - $P(X=x_i)=\sum_{j=1}^{L}P(X=x_i,Y=y_j)$
- 条件概率
    - 在事件$X=x_i$发生的情况下，事件$Y=y_j$发生的概率
    - Product Rule
        - $P(X=x_i,Y=y_j)=P(Y=y_j|X=x_i)P(X=x_i)$

Beyes' theorem

$$P(Y|X)=\frac{P(X|Y)P(Y)}{\sum_Y P(X|Y)P(Y)}$$

- PDF与CDF
  - $f_X(x)=\frac{\mathrm{d}F_X(x)}{\mathrm{d}x}$
  - 所以$F_X(k)=\int_{-\infty}^{k}F_X(x)\mathrm{d}x$
  - 且
  $P(x\le X\le x+\Delta x)=F_X(x+\Delta x)-F_X(x)=\int_x^{x+\Delta x}f_X(x)\mathrm{d}x=f_X(\xi)\Delta x\approx f_X(x)\Delta x$
  感觉不如看CS229-Probability

02-机器学习-线性模型Part01

任务

- 有监督学习
    - 分类问题、回归问题…
- 无监督学习
    - 聚类、密度估计、降维…
- 半监督学习
- 弱监督学习
- 强化学习

经验

- 训练数据
- 测试数据

表现

- 表现该如何衡量?
  - 损失函数$loss=\mathcal{L}(f,\mathbb{D})$
  目标：构建预测器$f:\mathbb{X}\to\mathbb{Y}$，能够做出合理预测
  途径：最小化损失函数的期望$\mathbb{E}[\mathcal{L}(f,\mathbb{D})]$

线性回归

> **Note**
>
> 连续数值预测：回归问题
> 离散数值预测：分类问题

目标：构建一个预测器$f:\mathbb{X}\to\mathbb{Y}$来最小化损失函数
线性模型：$f(\mathbf{x})=\sum_{i=1}^{d}w_ix_i+\mathbf{b}=\mathbf{w}^\top\mathbf{x}+\mathbf{b}$
给定数据集：$\mathbb{D}=\{(\mathbf{x_1},y_1),(\mathbf{x_2},y_2),\cdots,(\mathbf{x_n},y_n)\}$，求$\mathbf{w}$使得

$$\mathcal{L}(\mathbf{w},\mathbb{D})=E[(f(\mathbf{x})-y)^2]$$

最小

由大数定理，我们使用 经验均值/Empirical Mean 估计期望：

$$\begin{aligned}l(\mathbf{w},\mathbb{D})&=\frac{1}{|\mathbb{D}|}\sum_{(\mathbf{x},y)\in\mathbb{D}}(f(\mathbf{x})-y)^2\\&=\frac{1}{|\mathbb{D}|}\sum_{(\mathbf{x},y)\in\mathbb{D}}\left(y-\mathbf{w}^\top\mathbf{x}-\mathbf{b}\right)^2\end{aligned}$$

从而

$$\begin{aligned}(\mathbf{w}^*,b^*)&=\arg\min_{(\mathbf{w},b)}\frac{1}{|\mathbb{D}|}\sum_{(\mathbf{x},y)\in\mathbb{D}}\left(y-\mathbf{w}^\top\mathbf{x}-\mathbf{b}\right)^2\\&=\frac{1}{|\mathbb{D}|}\arg\min_{\beta}\sum_{i=1}^{n}(\mathbf{X}_i\beta-y_i)^2\\&=\frac{1}{|\mathbb{D}|}\arg\min_{\beta}\|\mathbf{A}\beta-\mathbf{y}\|^2\end{aligned}$$

其中

$$\mathbf{X}_i^\top=\begin{pmatrix}x_i^{(1)}\\\vdots\\x_i^{(d)}\\1\end{pmatrix}\qquad\mathbf{A}=\begin{pmatrix}\mathbf{X}_1\\\vdots\\\mathbf{X}_n\end{pmatrix}\qquad\beta=\begin{pmatrix}w_1\\\vdots\\w_n\\b\end{pmatrix}\qquad\mathbf{y}=\begin{pmatrix}\mathbf{y}_1\\\vdots\\\mathbf{y}_n\end{pmatrix}$$

令函数$\mathcal{J}(\beta)=\|\mathbf{A}\beta-\mathbf{Y}\|^2=(\mathbf{A}\beta-\mathbf{Y})^\top(\mathbf{A}\beta-\mathbf{Y})=\beta^\top\mathbf{A}^\top\mathbf{A}\beta-\mathbf{Y}^\top\mathbf{A}\beta-\beta^\top\mathbf{A}^\top\mathbf{Y}+\mathbf{Y}^\top\mathbf{Y}$
求导：

$$\frac{\partial\mathcal{J}}{\partial\beta}|_{\hat\beta}=2\mathbf{A}^\top\mathbf{A}\hat\beta-2\mathbf{A}^\top\mathbf{y}=0$$

即

$$\mathbf{A}^\top\mathbf{A}\hat\beta=\mathbf{A}^\top\mathbf{y}$$

当$\mathbf{A}^\top\mathbf{A}$可逆时，可以计算

$$\widehat{\beta} = \left(\mathbf{A}^\top\mathbf{A}\right)^{-1}\mathbf{A}^\top\mathbf{y}$$

什么时候可逆？什么时候不可逆？

- 样本数量 < 特征维度时不可逆（方程组欠定）
  - 不可逆时使用正则化/Regularization

但是，当矩阵大小非常大时候，即使$\mathbf{A}^\top\mathbf{A}$可逆，求解矩阵的逆开销也是非常大的
有没有什么更好的方法？

> 考虑优化问题！

梯度下降法

求$J(\beta)$的最小值，由于它是convex function，可以通过计算梯度的方法迭代
Step1. Initialize: β_0
Step2. Update:

$$\beta_{t+1} = \beta_t - \frac{\alpha}{2}\frac{\partial \mathcal{J}}{\partial \beta}|_{\beta_t}$$

Note

Step-size α的作用：

- 这个数值的大小代表学习率/learning rate
- small α：收敛速度慢，但不容易在最值附近摆动
- large α：收敛速度快，但有可能摆动

Stop. Convergence Condition:

$$\frac{\partial \mathcal{J}}{\partial \beta}|_{\beta_t} < \epsilon$$

按照该算法计算，最终可以最小化损失函数，进而获得预测器f

但是，如果矩阵$\mathbf{A}^\top\mathbf{A}$不可逆，我们应该如何最小化损失函数呢？

考虑矩阵不可逆的情况，这说明了样本数量小于特征维度，也就是说，此时预测器获得的信息不足以构建出整个模型，考虑人为增加一些条件。即，通过假设的方式人为“增加样本的数量”

“假设”，在贝叶斯统计中，可以体现为prior distribution，从而，我们可以运用贝叶斯统计的理论来解决这个问题

贝叶斯统计(from 卓致用)

我们要构建这个预测器$f:\mathbb{X}\to\mathbb{Y}$，可以通过 最大后验估计/Maximum A Posterior 的方式
由于后验概率$p\left(\beta \mid D\right) \propto p(D|\beta)p(\beta)$，所以

$$\max_{\beta} p(D|\beta)p(\beta) = \max_{\beta} \log p(D|\beta) + \log p(\beta)$$

$$\hat{\beta}_{\text{MAP}} = arg\max_{\beta} \underbrace{\log p\left(\{(X_i, Y_i)\}_{i=1}^{n} \mid \beta, \sigma^2\right)}_{\text{log likelihood}} + \underbrace{logp\left(\beta\right)}_{\text{log prior}}$$

第一行的含义是，我们要最大化数据的似然函数和参数的先验概率的乘积。

- 似然函数表示数据（D）在给定参数 β 的情况下出现的概率
- 先验概率表示我们在看到数据之前对参数的信念。

最大化这个乘积等价于最大化它们的对数，因为对数是单调递增的函数。

第二行的第一个项代表的含义是，在给定参数 β 和方差 σ^2 的情况下，数据出现的概率。

> 在统计模型中：
>
> - β 通常代表模型的系数
> - σ^2 代表模型中的噪声或误差的方差。即使我们有了 β，我们还需要知道数据中的变异性（或不确定性）有多大，这就是为什么 σ^2 是重要的。
>
> 在某些模型，比如线性回归中，我们假设数据 Y 是由自变量 X 的线性组合（由 β 确定）加上一些随机噪声（由 σ^2 描述）生成的。这个噪声代表了除了 X 影响 Y 之外的其它因素。所以，σ^2 帮助我们了解除了主要效应（由 β 描述）之外，数据中还有多少随机波动。

我们采取高斯先验，也即假设参数遵循高斯分布（也称为正态分布）。那么也就有
$\beta \sim N(0, \tau^2 I)$。

这表示：

- 参数 β 是一个 N 维向量，其中 N 是特征的数量
- 其遵循均值为 0，方差为 τ^2 的多元高斯分布
- $\tau^2 I$ 是指协方差矩阵为 τ^2 的对角矩阵，这代表 β 的每个元素都是相互独立的，且每个元素的方差都是 τ^2。
- 也就是说，各个维度独立同分布（iid）。

β 的概率密度分布函数按照矩阵表示，则是：

$$p(\beta) = \frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(\beta-\mu)^T\Sigma^{-1}(\beta-\mu)}$$

> 可以比较一维版本来理解~
>
> 其中的 $|\Sigma|$ 是协方差矩阵的行列式，它的作用是保证概率密度函数的总面积为 1。而当它为对角矩阵时，还能额外保证各个维度彼此独立。

所以，我们有 $p(\beta) \propto e^{-\beta^T\beta/2\tau^2}$。

这不包括归一化常数。$\propto$ 表示成比例，意味着这是未归一化的概率密度，它的形状随着 β 的变化而变化，但是总面积（概率总和）是固定的。$\beta^T\beta$ 是 β 的二次项，表示参数向量的长度的平方。

关于这一部分，可以阅读 钱默吟/多元高斯分布完全解析，讲的很详细。

这个式子的一个直观理解，就是假设 β 是一个二维的，那么我们可以可视化这个分布：

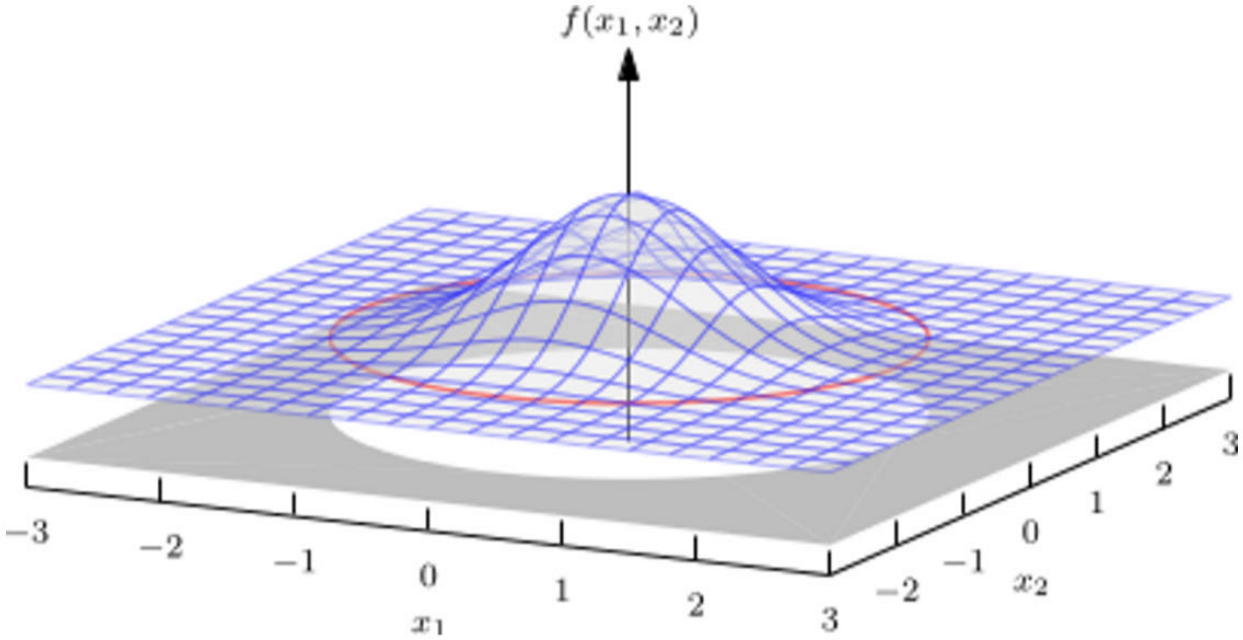

那么在这个图中，任意一个点都代表一个高斯分布，而 $f(x_1, x_2)$ 就是这个点的概率密度。我们可以看到，这个分布是关于原点对称的，这也是 $p(\beta)$ 中的 $\beta^T\beta$ 的作用，这代表了我们对于变量的顺序是没有偏好的。

由于$p(\beta) = \frac{1}{(2\pi)^{n/2}|\Sigma|^{1/2}} e^{-\frac{1}{2}(\beta-\mu)^{T\Sigma^{-1}(\beta-\mu)}} \propto e^{-\frac{1}{2}(\beta-\mu)^T\Sigma^{-1}(\beta-\mu)}$ 所以，$\log p(\beta) \propto \| \beta \|_2^2$

$$\hat{\beta}_{\mathbf{MAP}} = arg\min \sum_{i=1}^{n} (Y_i - X_i\beta)^2 + \lambda \| \beta \|_2^2$$

为什么刚才是 $arg\max$，现在又变成了 $arg\min$？简单说明就是，刚才我们要最大化从已知的 β 中得到数据真实分布的概率，这就等价于最小化使用我们的模型，从 X 中得到的数据的误差（也即最大似然估计）。

而 λ 是一个超参数，它的作用是控制我们对于参数的偏好，也就是我们对于模型的复杂度的偏好。在后续的学习中，我们会知道 $\lambda \| \beta \|_2^2$ 其实是一个正则项，它的作用是防止过拟合。

当我们对于 β 的先验假设不一样时，这个惩罚项（正则项）也会不一样。但大致原理不变，于是我们对这个形式加以推广，得到了类似如下的公式：

$$min_\beta (\mathbf{A}\beta - \mathbf{Y})^T(\mathbf{A}\beta - \mathbf{Y}) + \lambda \text{pen}(\beta) = minJ(\beta) + \lambda \text{pen}(\beta)$$

其中，$J(\beta)$ 是我们的损失函数，$\text{pen}(\beta)$ 是惩罚项。

对于惩罚项，我们一般有两个选择：

- L1 正则（1-范数）：$\text{pen}(\beta) = \| \beta \|_1 = \sum_{i=1}^{n} |\beta_i|$
- L2 正则（2-范数）：$\text{pen}(\beta) = \| \beta \|_2^2 = \sum_{i=1}^{n} \beta_i^2$

最终，我们得到**广义的线性模型**，我们可以考虑任意一种单调可微的函数 $g(\cdot)$：

$$y = g^{-1}(w^T x + b)$$

其中，$g(\cdot)$ 是激活函数，它的作用是将线性模型的输出转换为我们想要的输出，也即将线性模型的输出转换为一个非线性的预测值。比如，当 $g(\cdot)$ 是恒等函数时，我们就得到了线性回归；当 $g(\cdot)$ 是 sigmoid 函数时，我们就得到了逻辑回归。

02-机器学习-线性模型Part02

- Logistic Regression/Classification

> **Question**
> 如何用线性模型将X分类到离散labels Y?
> - 找一个单调可微的函数将Y和预测值联系起来
> - **Unit-step function.**
>
> $$y(z) = \begin{cases} 0, & z < 0 \\ 0.5, & z = 0 \\ 1, & z > 0 \end{cases}$$
>
> - **Sigmoid (Logistic) function.**
>
> $$y(z) = \frac{1}{1 + e^{-z}}$$

其中$z = w^T x + b$，从而：

$$y = \frac{1}{1 + e^{-(w^T x + b)}}$$

也可以表示为：

$$\log \frac{y}{1 - y} = w^T x + b$$

> **Note**
>
> $$\frac{\partial sigmoid(x)}{\partial x} = sigmoid(x)\,(1 - sigmoid(x))$$

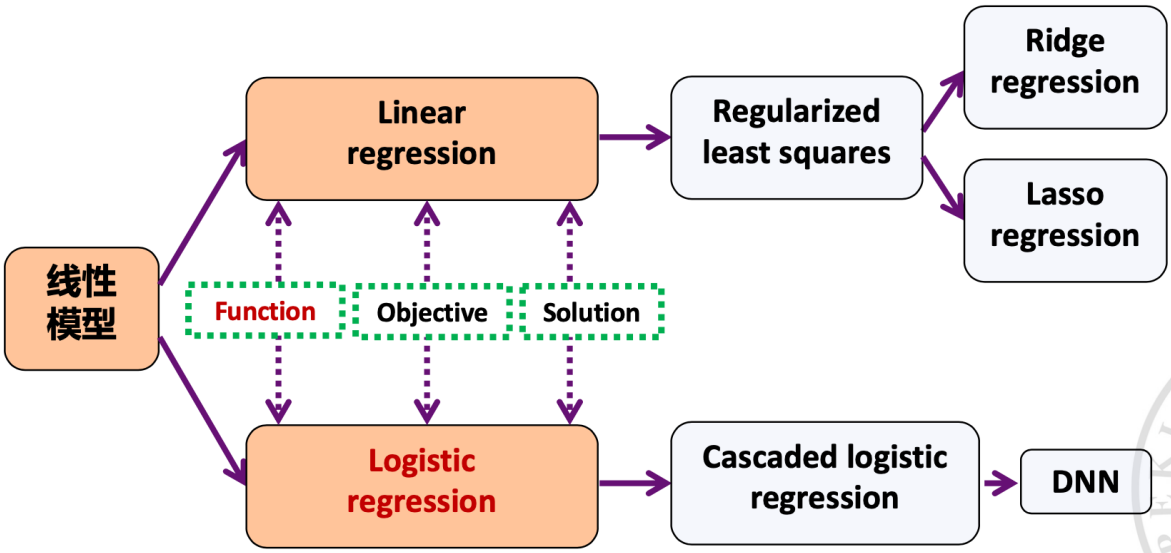

训练步骤：

Step1. 给定$\mathbf{x}$估计其出现$C_1 \mid x$的概率$P_{w,b}(C_1 \mid \mathbf{x}) = f_{w,b}(\mathbf{x})$，其中$f_{w,b}(\mathbf{x}) = \sigma\left(\sum_i w_i x_i + b\right)$

Step2. 找出目标函数/Objective function
给定训练数据

$$\begin{array}{ccccc} x^1 & x^2 & x^3 & \cdots\cdots & x^N \\ C_1 & C_1 & C_2 & \cdots\cdots & C_1 \end{array}$$

假设这些数据是基于$P_{w,b}(C_1 \mid \mathbf{x}) = f_{w,b}(\mathbf{x})$生成的
那么给定$\mathbf{w}$与$\mathbf{b}$，生成这些数据的概率是：

$$\mathcal{L}(w,b) = f_{w,b_r}(x^1) f_{w,b}(x^2)\left(1 - f_{w,b}(x^3)\right)\cdots f_{w,b}(x^N)$$

所以最优的$\mathbf{w}^*, \mathbf{b}^*$是：

$$w^*, b^* = \arg\max_{w,b} \mathcal{L}(w,b)$$

记label $\hat{y}$ 满足

$$\hat{y} = \begin{cases} 1, & C_1 \\ 0, & C_2 \end{cases}$$

所以

$$w^*, b^* = arg\max_{w,b} \mathcal{L}(w,b) = arg\min_{w,b} -log\mathcal{L}(w,b)$$

从而

$$\begin{aligned} -log\mathcal{L}(w,b) &= -\left(log f_{w,b}(x^1) + log f_{w,b}(x^2) + log\left(1 - f_{w,b}(x^3)\right)\cdots + log f_{w,b}(x^N)\right. \\ &= \underbrace{\sum_n -\left[\hat{y}^n log f_{w,b}(x^n) + (1-\hat{y}^n) log\left(1 - f_{w,b}(x^n)\right)\right]}_{\text{Cross Entropy}} \end{aligned}$$

Important

上面目标函数的负对数恰好是交叉熵/Cross Entropy

- 假设现在一个样本集合中有两个概率分布p与q，其中p代表真实分布，q代表非真实分布
- 用p衡量一个样本所需要的编码长度的期望为Cross Entropy：

$$H(p) = \sum_i p(i) \log(\frac{1}{q(i)})$$

- 对于离散变量：

$$H(p) = \sum_i p(i) \log(\frac{1}{q(i)})$$

- 对于连续变量：

$$H(p) = -\int_X P(x) \log Q(x) \mathrm{d}x$$

Step3. 梯度下降
计算梯度

$$\begin{aligned}
\frac{\partial(-log\mathcal{L}(w,b))}{\partial w_i} &= \sum_n -\left[\hat{y}^n \frac{\partial}{\partial w_i} log f_{w,b}(x^n) + (1-\hat{y}^n)\frac{\partial}{\partial w_i} log\left(1 - f_{w,b}(x^n)\right)\right] \\
&= \sum_n -\left[\hat{y}^n(1-f_{w,b}(x^n))x_i^n + (1-\hat{y}^n)f_{w,b}(x^n)x_i^n\right] \\
&= \sum_n -\left(\hat{y}^n - f_{w,b}(x^n)\right)x_i^n \\
&\propto \text{difference between label and prediction}
\end{aligned}$$

更新weight

$$w_i \leftarrow w_i - \eta \sum_n -\left(\hat{y}^n - f_{w,b}(x^n)\right)x_i^n$$

Question

为什么不用Square Error Loss Function?

如果用Square Error：

$$\mathcal{L}(f) = \frac{1}{2}\sum_n \left(f_{w,b}(x^n) - \hat{y}^n\right)^2$$

求梯度：

$$\frac{\partial \mathcal{L}}{\partial w_i} = (f_{w,b}(x) - \hat{y}) f_{w,b}(x) \left(1 - f_{w,b}(x)\right) x_i$$

无论$f_{w,b}(x^i) = 1/0$ 梯度都是0