AI基础

01-数学基础

01-1 Linear Algebra

01-2 Regression

> **Question**
>
> 在一组数据点中找到一个多项式函数，拟合这组数据 (Linear/Polynomial Regression)
> 数据为 $\mathbf{x} = (x_1, \ldots, x_N)^T, \mathbf{t} = (t_1, \ldots, t_N)^T$
> 求"最佳"参数$\mathbf{w} = (w_0, \ldots, w_M)^T$

令M次多项式函数$y(x, \mathbf{w}) = \sum_{j=0}^{M} w_j x^j$，误差函数$E(\mathbf{w}) = \frac{1}{2}\sum_{n=1}^{N}(y(x_n, \mathbf{w}) - t_n)^2$，"最佳拟合"即为使得$E(\mathbb{w})$最小的$\mathbb{w}$

> **是不是$\mathbb{w}$越大越好呢?**
>
> 多项式次数过高会导致**过拟合**
> 训练数据过少，参数过多可能会**过拟合**

- 过拟合解决方案:
  - 增加数据量
  - 权重正则化

01-3 Probability Theory

CS229-Mathmatical Fundamentals

[CS229-Probability Review]

概率的定义

- 概率三要素
  - 样本空间Ω
  - 事件空间$\mathcal{F} \subset 2^{\Omega}$
  - 概率测度$P : \mathcal{F} \to [0, 1]$
- 联合概率:
  - $X = x_i$ 和 $Y = y_j$同时发生的概率

    - Sum Rule
        - $P(X=x_i)=\sum_{j=1}^{L}P(X=x_i,Y=y_j)$
- 条件概率
    - 在事件$X=x_i$发生的情况下，事件$Y=y_j$发生的概率
    - Product Rule
        - $P(X=x_i,Y=y_j)=P(Y=y_j|X=x_i)P(X=x_i)$

Beyes' theorem

$$P(Y|X)=\frac{P(X|Y)P(Y)}{\sum_Y P(X|Y)P(Y)}$$

- PDF与CDF
  - $f_X(x)=\frac{\mathrm{d}F_X(x)}{\mathrm{d}x}$
  - 所以$F_X(k)=\int_{-\infty}^{k}F_X(x)\mathrm{d}x$
  - 且
  $P(x\le X\le x+\Delta x)=F_X(x+\Delta x)-F_X(x)=\int_x^{x+\Delta x}f_X(x)\mathrm{d}x=f_X(\xi)\Delta x\approx f_X(x)\Delta x$
  感觉不如看CS229-Probability

01-Python编程基础

02-机器学习

任务

经验

训练数据

线性回归

Note

连续数值预测：回归问题
离散数值预测：分类问题

目标：构建一个预测器$f:\mathbb{X}\to\mathbb{Y}$来最小化损失函数
线性模型：$f(\mathbf{x})=\sum_{i=1}^{d}w_ix_i+\mathbf{b}=\mathbf{w}^\top\mathbf{x}+\mathbf{b}$
给定数据集：$\mathbb{D}=\{(\mathbf{x_1},y_1),(\mathbf{x_2},y_2),\cdots,(\mathbf{x_n},y_n)\}$，求$\mathbf{w}$使得

$$\mathcal{L}(\mathbf{w},\mathbb{D})=E[(f(\mathbf{x})-y)^2]$$

最小

由大数定理，我们使用均值估计期望：

$$
\begin{aligned}
l(\mathbf{w}, \mathbb{D}) &= \frac{1}{|\mathbb{D}|} \sum_{(\mathbf{x}, y) \in \mathbb{D}} (f(\mathbf{x}) - y)^2 \\
&= \frac{1}{|\mathbb{D}|} \sum_{(\mathbf{x}, y) \in \mathbb{D}} \left(y - \mathbf{w}^\top \mathbf{x} - \mathbf{b}\right)^2
\end{aligned}
$$

从而

$$
\begin{aligned}
(\mathbf{w}^*, b^*) &= \arg\min_{(\mathbf{w}, b)} \frac{1}{|\mathbb{D}|} \sum_{(\mathbf{x}, y) \in \mathbb{D}} \left(y - \mathbf{w}^\top \mathbf{x} - \mathbf{b}\right)^2 \\
&= \frac{1}{|\mathbb{D}|} \arg\min_{\beta} \sum_{i=1}^{n} (\mathbf{X}_i \beta - y_i)^2 \\
&= \frac{1}{|\mathbb{D}|} \arg\min_{\beta} \|\mathbf{A}\beta - \mathbf{y}\|^2
\end{aligned}
$$

其中

$$
\mathbf{X}_i^\top = \begin{pmatrix} x_i^{(1)} \\ \vdots \\ x_i^{(d)} \\ 1 \end{pmatrix} \qquad \mathbf{A} = \begin{pmatrix} \mathbf{X}_1 \\ \vdots \\ \mathbf{X}_n \end{pmatrix} \qquad \beta = \begin{pmatrix} w_1 \\ \vdots \\ w_n \\ b \end{pmatrix} \qquad \mathbf{y} = \begin{pmatrix} \mathbf{y}_1 \\ \vdots \\ \mathbf{y}_n \end{pmatrix}
$$

令函数$\mathcal{J}(\beta) = \|\mathbf{A}\beta - \mathbf{Y}\|^2 = (\mathbf{A}\beta - \mathbf{Y})^\top (\mathbf{A}\beta - \mathbf{Y}) = \beta^\top \mathbf{A}^\top \mathbf{A}\beta - \mathbf{Y}^\top \mathbf{A}\beta - \beta^\top \mathbf{A}^\top \mathbf{Y} + \mathbf{Y}^\top \mathbf{Y}$
求导：

$$
\frac{\partial \mathcal{J}}{\partial \beta}|_{\hat{\beta}} = 2\mathbf{A}^\top \mathbf{A}\hat{\beta} - 2\mathbf{A}^\top \mathbf{y} = 0
$$

即

$$
\mathbf{A}^\top \mathbf{A}\hat{\beta} = \mathbf{A}^\top \mathbf{y}
$$

当$\mathbf{A}^\top \mathbf{A}$可逆时，可以计算。
什么时候可逆？什么时候不可逆？

- 样本数量 < 特征维度时不可逆（方程组欠定）
  - 不可逆时使用正则化/Regularization

梯度下降法

求$J(\beta)$的最小值，由于它是convex function，可以通过计算梯度的方法迭代
Step1. Initialize: β_0
Step2. Update:

$$
\beta_{t+1} = \beta_t - \frac{\alpha}{2} \frac{\partial \mathcal{J}}{\partial \beta}|_{\beta_t}
$$

Stop. Convergence Condition:

$$\frac{\partial \mathcal{J}}{\partial \beta}|_{\beta_t} < \epsilon$$